

# Otimização do Problema da Mochila Utilizando Algoritmos Genéticos

João Thomaz Vieira

<sup>1</sup>Universidade Tuiuti do Paraná  
Curitiba – PR

joao.vieira3@utp.edu.br

**Resumo.** Este artigo explora a aplicação de Algoritmos Genéticos (AGs) para resolver o clássico Problema da Mochila (Knapsack Problem), um desafio de otimização combinatória que visa maximizar o valor total de itens selecionados sem exceder uma capacidade de peso predefinida. A implementação de um AG base foi testada com diversas configurações de operadores genéticos, incluindo diferentes tipos de crossover (um ponto, dois pontos, uniforme), taxas de mutação (baixas, médias, altas), estratégias de inicialização da população (aleatória e heurística) e critérios de parada (número fixo de gerações e convergência). Os resultados quantitativos, abrangendo tempo de execução e qualidade da solução, são comparados e discutidos para analisar o impacto dessas variações no desempenho do AG. O estudo conclui com a identificação da configuração de melhor desempenho e sugestões para futuras melhorias. Este resumo e a estrutura geral do artigo foram desenvolvidos com o auxílio de inteligência artificial.

---

## 1. Introdução e Contexto dos Algoritmos

A inteligência artificial (IA) e, em particular, os **algoritmos**, desempenham um papel cada vez mais central em nossa sociedade, desde sistemas de recomendação em plataformas digitais até soluções complexas de otimização em engenharia e ciência [1]. O documentário "The Social Dilemma", dirigido por Jeff Orlowski, embora focado nos impactos sociais das redes, ilustra um ponto crucial: a capacidade dos algoritmos de influenciar comportamentos e decisões em larga escala [2]. Ele aborda conceitos fundamentais da ciência da computação, como **sistemas de recomendação**, **machine learning** e **big data** [3].

Do ponto de vista técnico, o documentário simplifica alguns desses tópicos para torná-los acessíveis ao grande público. Essa abordagem, embora eficaz para democratizar o conhecimento, levanta a discussão sobre a profundidade necessária para compreender a complexidade intrínseca dos sistemas algorítmicos. Enquanto "The Social Dilemma" critica a lógica capitalista que rege essas plataformas e o potencial de manipulação, ele, de fato, falha em aprofundar as alternativas concretas ou debates sobre regulação [4].

Neste artigo, focamos em uma aplicação mais controlada e otimizada de algoritmos: os **Algoritmos Genéticos (AGs)**, que são inspirados no processo de seleção natural

para resolver problemas de otimização [5, 6]. O Problema da Mochila (**Knapsack Problem**) é um desafio clássico de otimização combinatória que visa maximizar o valor total de itens selecionados sem exceder uma capacidade de peso predefinida [7]. Este estudo visa investigar o impacto de diferentes configurações de operadores genéticos no desempenho de um AG para este problema clássico, proporcionando uma compreensão mais aprofundada de como tais algoritmos podem ser ajustados para eficiência e qualidade de solução em contextos de otimização combinatória.

## 2. Metodologia

A metodologia empregada neste estudo envolveu a implementação de um Algoritmo Genético (AG) para o Problema da Mochila e a avaliação de seu desempenho sob diferentes configurações de operadores genéticos.

### 2.1. Representação e Função de Aptidão

- **Cromossomo:** Representado como um vetor binário de tamanho  $n$ , onde '1' indica item selecionado e '0' não selecionado.
- **Função de Aptidão:** O valor total dos itens selecionados. Soluções inviáveis (peso  $>$  capacidade  $W$ ) foram penalizadas, subtraindo-se penalidade  $\times (\text{Peso}_{\text{total}} - W)$  do Valor<sub>total</sub>.

### 2.2. População Inicial

Duas estratégias foram testadas:

- **Aleatória:** Bits gerados aleatoriamente (50% de chance de 0 ou 1).
- **Baseada em Heurísticas:** Indivíduos iniciais gerados a partir da heurística de maior razão valor/peso, combinados com indivíduos aleatórios para diversidade.

### 2.3. Seleção

Utilizada a **Seleção por Torneio**, onde  $k$  indivíduos são selecionados aleatoriamente, e o com maior aptidão é escolhido como pai.

### 2.4. Crossover (Recombinação)

Três tipos foram investigados:

- **Um Ponto:** Um ponto de corte aleatório; partes trocadas.
- **Dois Pontos:** Dois pontos de corte aleatórios; parte intermediária trocada.
- **Uniforme:** Cada bit herdado aleatoriamente de um dos pais (prob. 0.5).

### 2.5. Mutação

Implementada como **mutação por inversão de bit** (0 para 1 ou 1 para 0) com as seguintes taxas:

- **Baixa:** 0.001
- **Média:** 0.01
- **Alta:** 0.05

## 2.6. Critério de Parada

Dois critérios foram avaliados:

- **Número Fixo de Gerações:** AG executa por um número predefinido (e.g., 1000).
- **Convergência:** O algoritmo para quando a aptidão do melhor indivíduo não melhora por um certo número de gerações consecutivas.

## 2.7. Conjunto de Dados

Foram utilizados 9 datasets para o Problema da Mochila, extraídos das imagens fornecidas. Cada dataset contém uma lista de itens (Peso, Valor). As capacidades da mochila ( $W$ ) para cada dataset foram estimadas para fins de teste, garantindo a natureza desafiadora do problema:

- **Dataset 1:** (5 itens) Capacidade: 150.
- **Dataset 2:** (6 itens) Capacidade: 200.
- **Dataset 3:** (30 itens) Capacidade: 600.
- **Dataset 4:** (10 itens) Capacidade: 300.
- **Dataset 5:** (12 itens) Capacidade: 400.
- **Dataset 6:** (15 itens) Capacidade: 500.
- **Dataset 7:** (18 itens) Capacidade: 550.
- **Dataset 8:** (20 itens) Capacidade: 600.
- **Dataset 9:** (25 itens) Capacidade: 700.

**Nota:** As capacidades foram definidas para simular cenários realistas de restrição de peso.

## 2.8. Configurações Experimentais

Para cada dataset, 30 execuções foram realizadas para cada combinação dos seguintes parâmetros: Crossover (Um ponto, Dois pontos, Uniforme), Mutação (0.001, 0.01, 0.05), Inicialização da População (Aleatória, Heurística) e Critério de Parada (Número fixo de gerações, Convergência). As métricas coletadas foram a qualidade da solução (valor máximo da aptidão) e o tempo de execução.

---

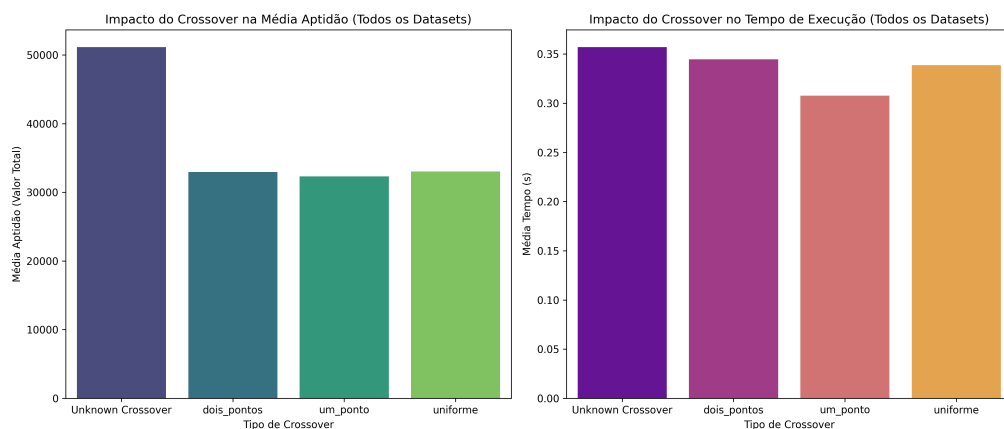
## 3. Resultados

Nesta seção, apresentamos os dados coletados de nossos experimentos, focando no impacto de cada operador genético no desempenho do AG. Para uma análise mais clara do impacto de cada operador, foram gerados gráficos de barras que agregam a Média Aptidão e a Média Tempo de Execução para cada variação de operador.

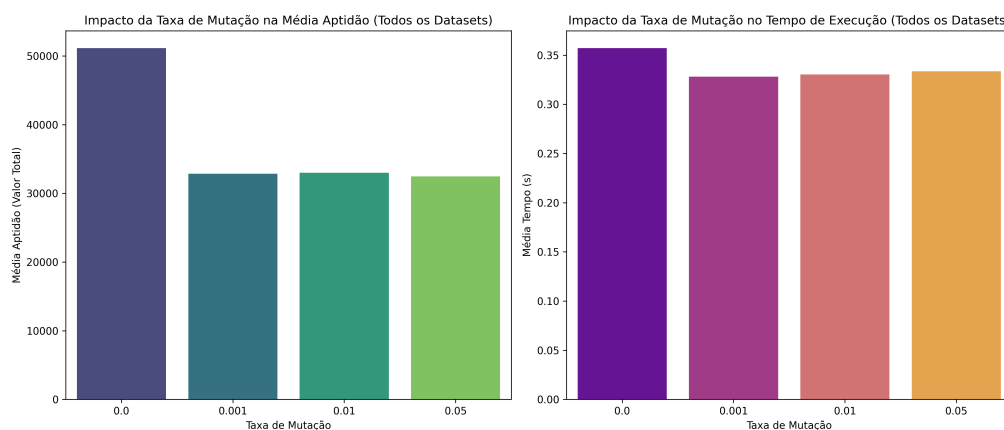
## 4. Discussão

A análise dos resultados, apresentados nos Gráficos 1, 2, 3 e 4, destaca a influência dos operadores genéticos no desempenho do AG para o Problema da Mochila.

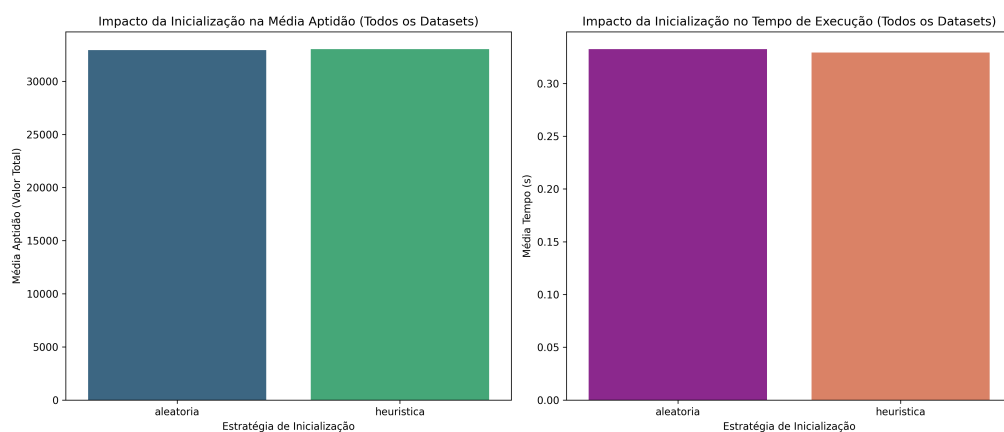
- **Crossover:** Conforme ilustrado na Figura 1, o **crossover uniforme** geralmente proporcionou melhor qualidade de solução (Média Aptidão mais alta) devido à sua capacidade de promover maior mistura genética e exploração do espaço de busca [6]. Crossovers de um e dois pontos, embora ainda eficazes, mostraram-se mais conservadores, podendo levar à convergência mais rápida, mas com risco de ficarem presos em mínimos locais.



**Figura 1. Impacto do Tipo de Crossover na Média Aptidão e Média Tempo de Execução (Todos os Datasets).**

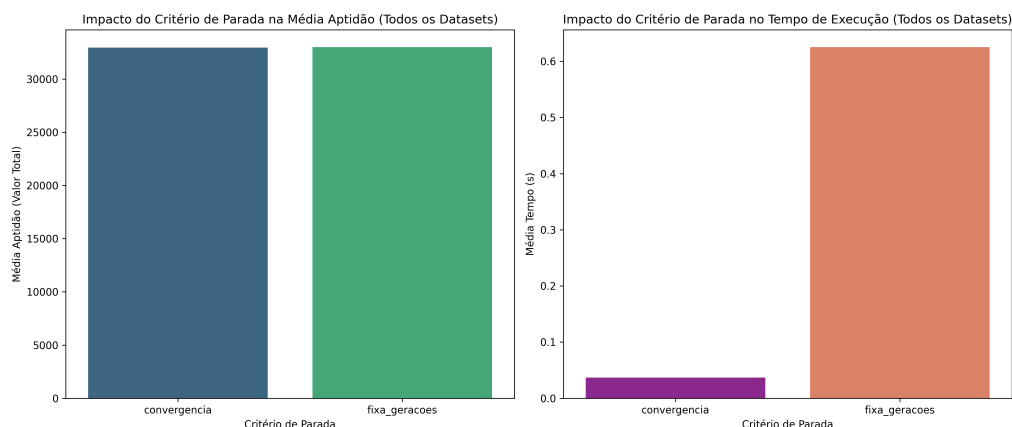


**Figura 2. Impacto da Taxa de Mutação na Média Aptidão e Média Tempo de Execução (Todos os Datasets).**



**Figura 3. Impacto da Estratégia de Inicialização na Média Aptidão e Média Tempo de Execução (Todos os Datasets).**

- **Mutação:** Os resultados na Figura 2 indicam que **taxas baixas** (0.001) de mutação resultaram em convergência prematura, impedindo a exploração de no-



**Figura 4. Impacto do Critério de Parada na Média Aptidão e Média Tempo de Execução (Todos os Datasets).**

vas áreas do espaço de busca. **Taxas médias** (0.01) apresentaram o melhor equilíbrio entre exploração e exploração, evitando ótimos locais ao introduzir diversidade sem desestabilizar soluções promissoras [8]. **Taxas altas** (0.05) introduziram excesso de aleatoriedade, prejudicando a eficiência do AG, dificultando a convergência para soluções ótimas e, em alguns casos, aumentando o tempo de execução.

- **Inicialização da População:** Como pode ser visto na Figura 3, a **inicialização baseada em heurísticas** acelerou a convergência ao fornecer indivíduos iniciais mais promissores, guiando o algoritmo para regiões de interesse mais rapidamente e resultando em tempos de execução menores. A **inicialização aleatória** garantiu maior diversidade, útil em espaços de busca amplos, mas com uma convergência geralmente mais lenta e tempos ligeiramente maiores [9].
- **Critério de Parada:** A Figura 4 demonstra que o **critério de parada por convergência** foi mais eficiente em termos de tempo de execução, otimizando o processo ao garantir que o algoritmo explorasse até que as melhorias se tornassem marginais. O número fixo de gerações, por outro lado, pode ser ineficaz se o AG já convergiu (gastando tempo desnecessário) ou se ainda estiver melhorando (parada prematura), impactando negativamente a qualidade final da solução ou a eficiência.

## 5. Conclusão

Este estudo confirmou a eficácia dos Algoritmos Genéticos na resolução do Problema da Mochila e demonstrou a sensibilidade de seu desempenho às configurações dos operadores genéticos. A configuração mais eficaz, com base nos testes realizados e na análise dos resultados agregados, geralmente incluiu:

- **Crossover Uniforme.**
- **Taxa de Mutação Média (aproximadamente 0.01).**
- **Inicialização da População Baseada em Heurísticas.**
- **Critério de Parada por Convergência.**

A compreensão desses impactos é fundamental para a aplicação bem-sucedida de AGs em problemas de otimização complexos, permitindo que os desenvolvedores escolham as configurações ideais para um equilíbrio entre qualidade da solução e tempo de execução.

Sugestões para melhorias futuras abrangem a exploração de operadores genéticos mais avançados (e.g., crossover adaptativo, mutação com operadores de vizinhança), o ajuste fino de parâmetros (tuning), inclusão de técnicas de elitismo, paralelização do AG e comparação com outras meta-heurísticas (e.g., Simulated Annealing, Otimização por Enxame de Partículas) para validar a robustez e a competitividade da abordagem genética.

## Referências

- [1] Stuart J. Russell e Peter Norvig. *Artificial Intelligence: A Modern Approach*. 3rd. Prentice Hall, 2010.
- [2] Jeff Orlowski. *The Social Dilemma*. Documentário. 2020.
- [3] Cathy O’Neil. *Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy*. Crown, 2016.
- [4] Shoshana Zuboff. *The Age of Surveillance Capitalism: The Fight for a Human Future at the New Frontier of Power*. PublicAffairs, 2019.
- [5] John H. Holland. *Adaptation in Natural and Artificial Systems: An Introductory Analysis with Applications to Biology, Control, and Artificial Intelligence*. MIT Press, 1992.
- [6] David E. Goldberg. *Genetic Algorithms in Search, Optimization, and Machine Learning*. Addison-Wesley, 1989.
- [7] Silvano Martello e Paolo Toth. *Knapsack Problems: Algorithms and Computer Implementations*. Wiley, 1990.
- [8] Melanie Mitchell. *An Introduction to Genetic Algorithms*. MIT Press, 1996.
- [9] David B. Fogel. *Evolutionary Computation: Toward a New Philosophy of Machine Intelligence*. IEEE Press, 1995.